SGD, Adam et Cie : qui est le meilleur entraîneur de neurones ?

ROUX-DESSARPS GABRIEL
30077

Plan de la présentation

- Introduction aux CNN
- Mise en oeuvre sur Python
- Aspects théoriques des optimiseurs
- Comparaison des optimiseurs

Introduction aux CNN

La structure

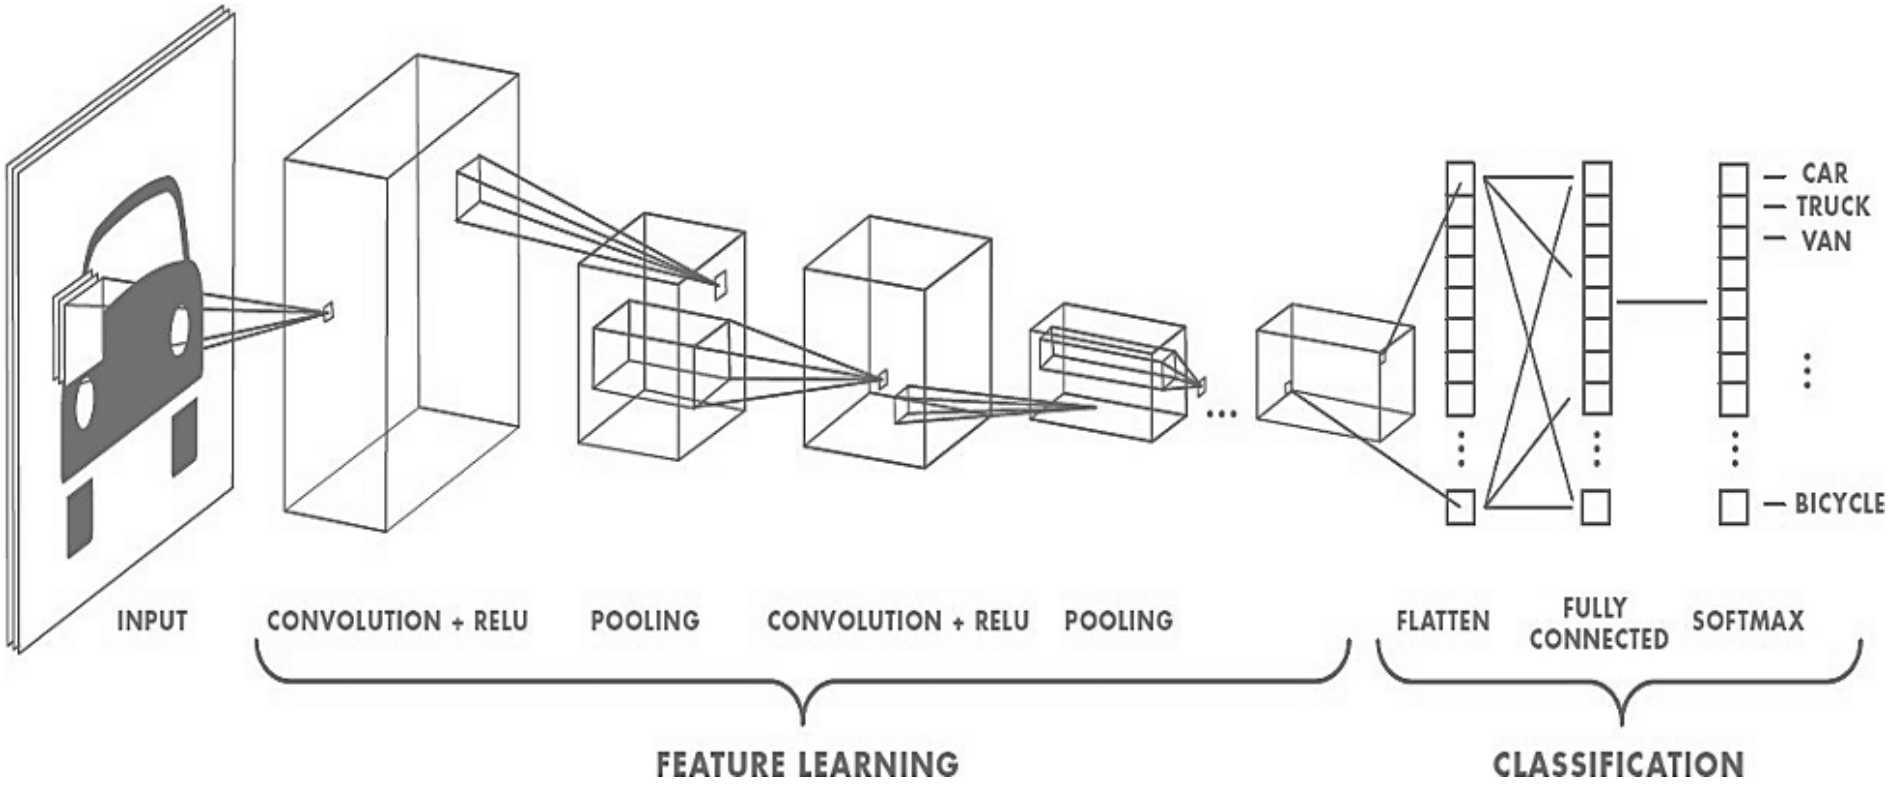

Mise en oeuvre sur Python

→ Pre-processing

→ Personalisation du réseau avec Keras

→ Logiciel de calculs

Aspects théoriques des optimiseurs

Les variables

Définition

$\Theta \subset \mathbb{R}^n$: Espace des paramètres

$\mathcal{E} = (x^{(i)}, y^{(i)})_{1 \leq i \leq m}$: Espace des données d'entraînement

Expression de $L(\theta)$

$$L(\theta) = \frac{1}{m} \sum_{i=1}^{m} \ell(f_\theta(x^{(i)}), y^{(i)})$$

où :

$f_\theta(x^{(i)})$ est la prédiction du modèle pour l'entrée $x^{(i)}$ avec les paramètres θ.

ℓ est la fonction de coût

Formule pour la classification multi-classes

$$\ell(f_\theta(x), y) = -\log(f_{\theta,y}(x))$$

où :

$f_{\theta,y}(x)$ est la probabilité prédite pour la classe y.

Aspects théoriques des optimiseurs

Premier objectif

Calcul de $\vec{\nabla} L(\theta)$ dans le but d'optimiser la fonction L

C'est la partie la plus couteuse du CNN.

$\longrightarrow$ Le choix de l'optmiseur influence peu la durée d'exécution.

Définiton

$$\theta_{n+1} = \theta_n - \alpha \vec{\nabla} L(\theta_n)$$

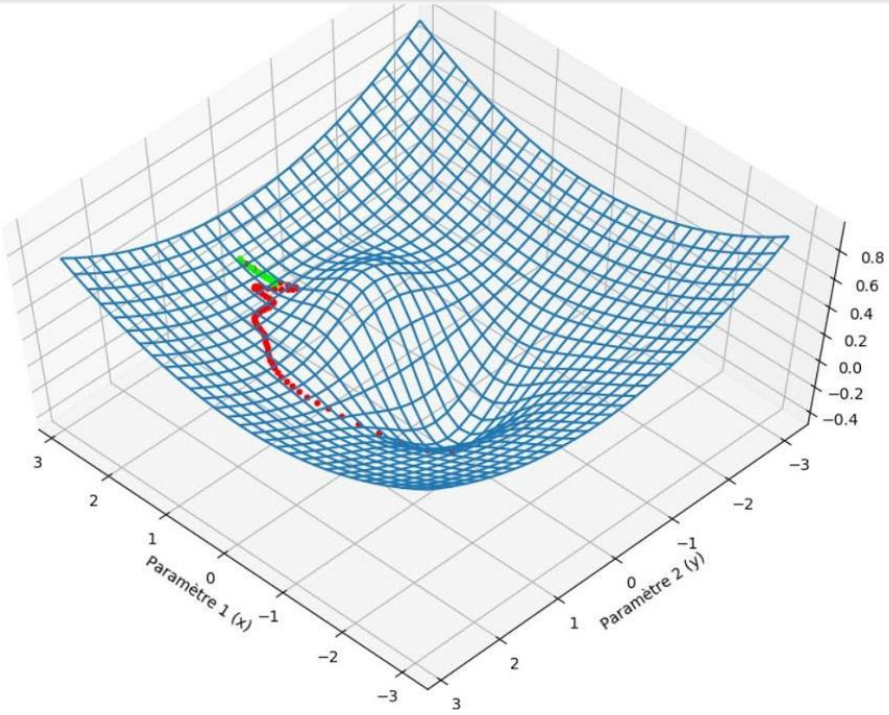

Figure: Visualisation d'une descente de gradient

Aspects théoriques des optimiseurs

Une amélioration : la descente du gradient stochastique

Idée

$$L(\theta) = \frac{1}{\#B} \sum_{i \in B} \ell(f_\theta(x^{(i)}), y^{(i)})$$

Avantages et inconvénients

- Réduction des calculs
- Echappe aux minimums locaux
- Convergence plus lente (en nombre d'itérations)

Pour SGD, le choix d'un bon taux d'apprentissage est crucial.

Problématique

Le choix de α dépend de la base de donnée.

$\longrightarrow$ Il faut trouver un moyen rapide d'avoir un bon α.

Aspects théoriques des optimiseurs

Une première approche itérative

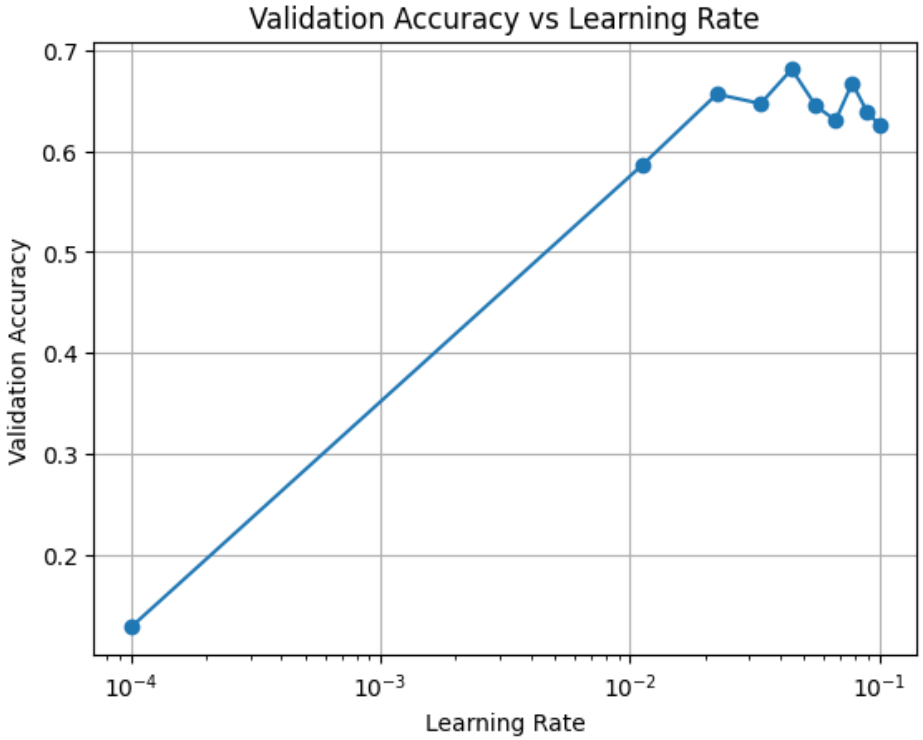

Résultats

$\longrightarrow$ long.

$\longrightarrow$ $\alpha_{meilleur}$ très approximatif.

Aspects théoriques des optmiseurs

Une meilleure solution : l'optimisation bayésienne

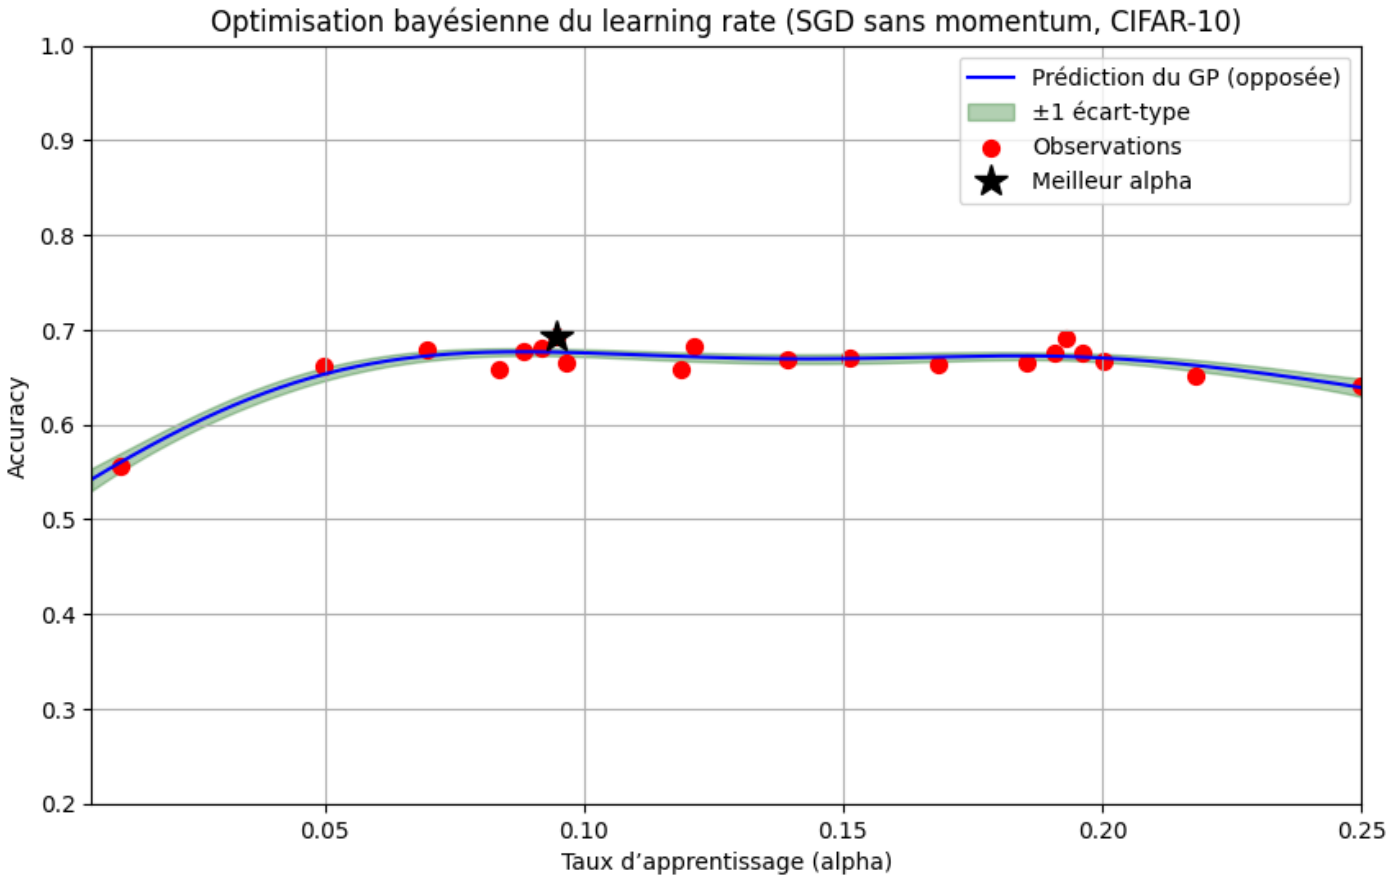

Aspects théoriques des optimiseurs

SGD + Momentum

Objectif

Accélérer la convergence de la descente de gradient tout en réduisant les oscillations.

Formule du SGD avec momentum

$$v_{t+1} = \gamma v_t + \alpha \nabla J(\theta_t)$$
$$\theta_{t+1} = \theta_t - v_{t+1}$$

où :

α : taux d'apprentissage

γ : coefficient de momentum ($\approx 0{,}9$)

v_t : vitesse accumulée

Aspects théoriques des optimiseurs

L'impact des hyperparamètres pour SGD + Momentum

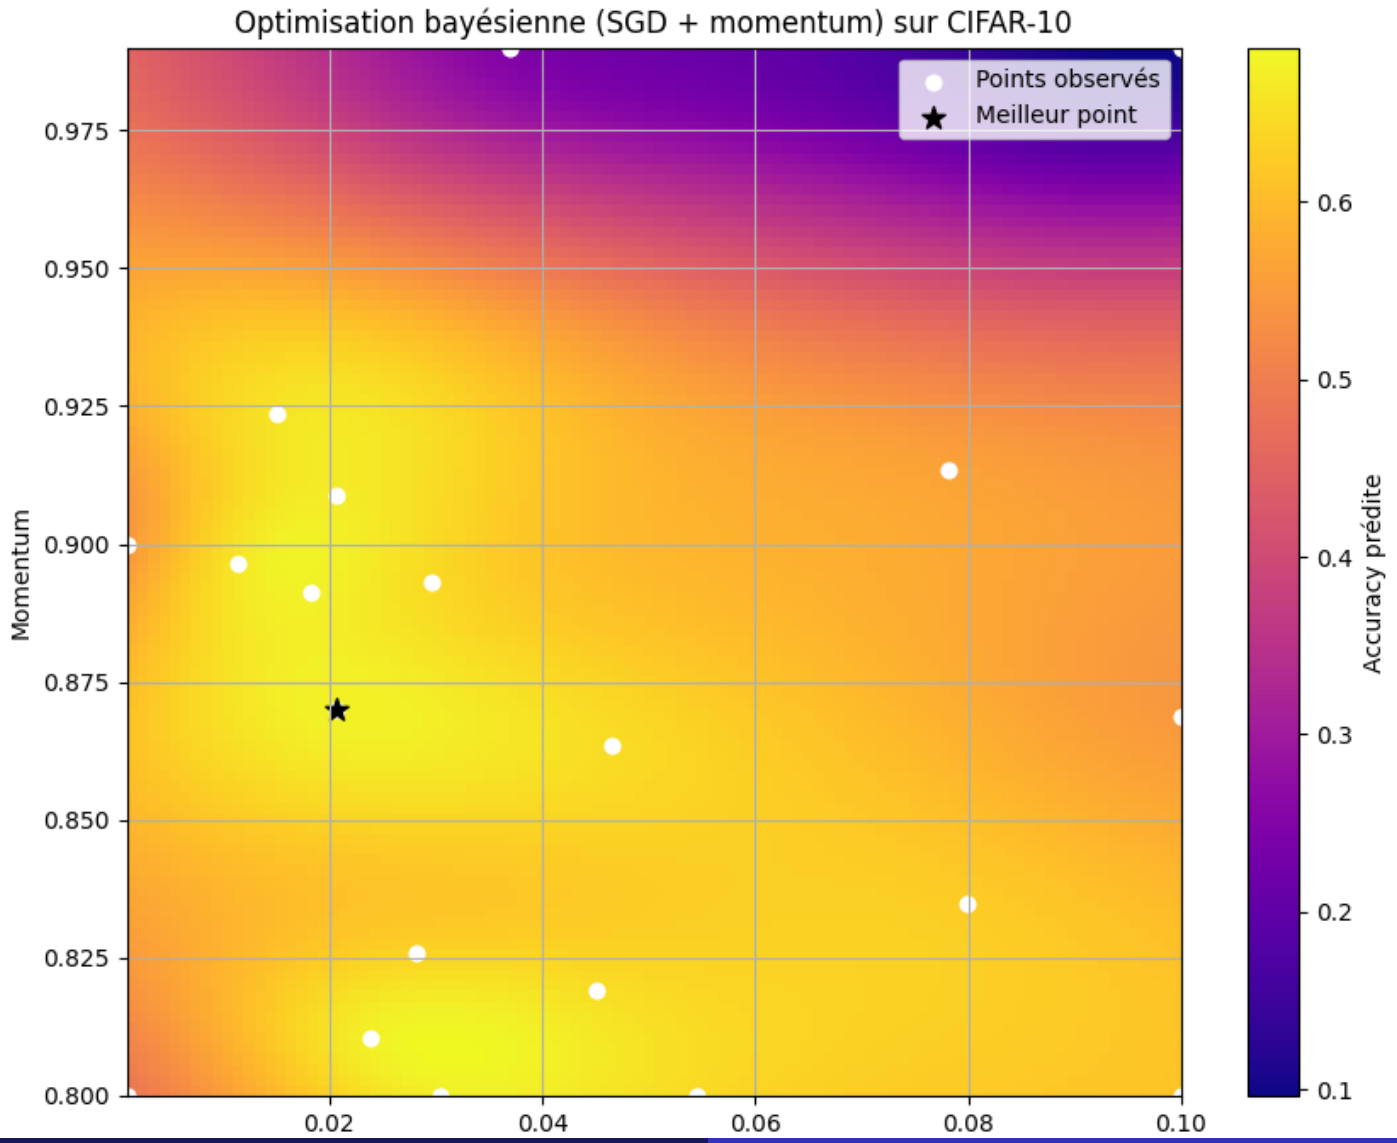

Comparaison des optimiseurs

Convergence sur CIFAR-10

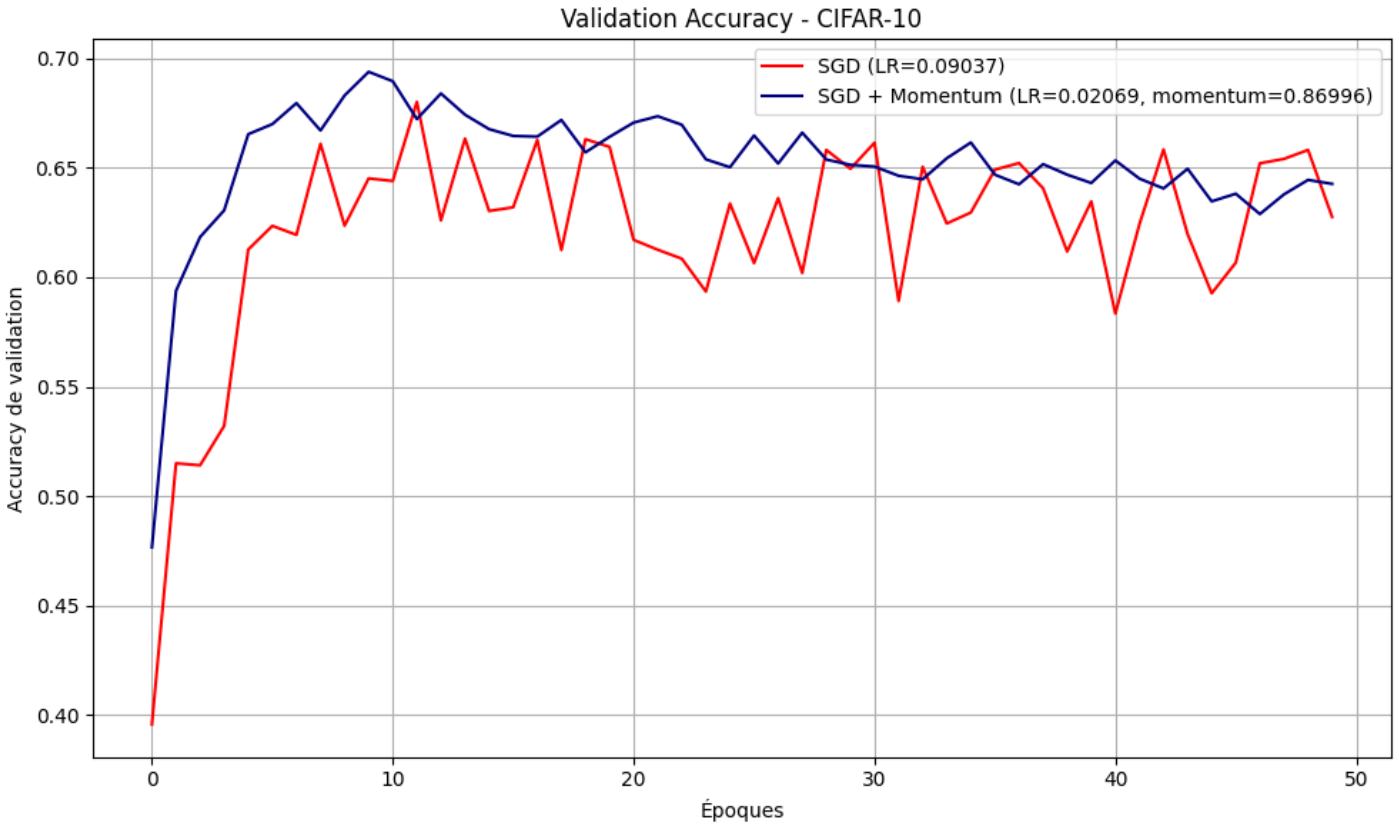

Comparaison des optimiseurs

Une comparaison visuelle

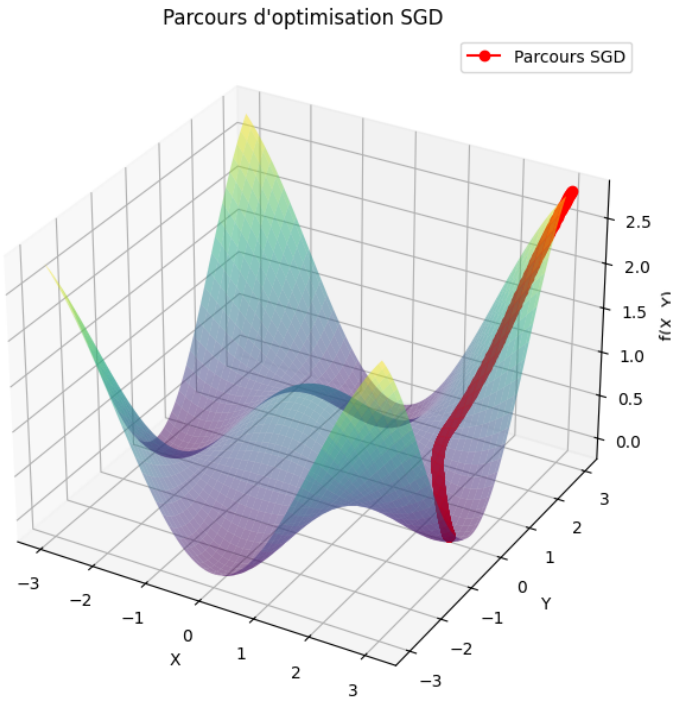

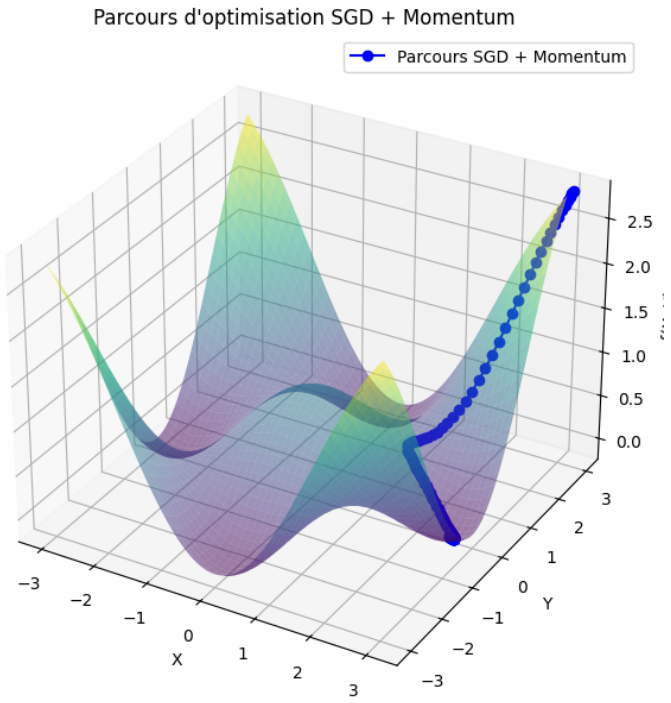

Nombre d'itérations

SGD $\longrightarrow$ 832

SGD + Momentum $\longrightarrow$ 112

Comparaison des optimiseurs

Avantages par rapport au SGD classique

Convergence améliorée

Permet une descente plus rapide.

Réduction des oscillations

L'inertie empêche les grands changements de direction à chaque itération.

Le principe

$\epsilon, \gamma > 0,\ \alpha, \beta \in]0, 1[$

$m_{k+1} \longleftarrow \alpha m_k + (1-\alpha)\nabla L(\theta_k)$

$\hat{m_{k+1}} \longleftarrow \frac{m_{k+1}}{1-\alpha^{k+1}}$ (débiaisage)

$v_{k+1} \longleftarrow \beta v_k + (1-\beta)\nabla L(\theta_k)^2$

$\hat{v_{k+1}} \longleftarrow \frac{v_{k+1}}{1-\beta^{k+1}}$ (débiaisage)

$\theta_{k+1} \longleftarrow \theta_k - \frac{\gamma \hat{m_{k+1}}}{\epsilon + \sqrt{\hat{v_{k+1}}}}$

Comprendre

$m_{k+1} = (1-\alpha)\sum_{i=0}^{k} \alpha^i \nabla L(\theta_{k-i})$: Moyenne glissante exponentielle

$\hat{m_{k+1}} = \sum_{i=0}^{k} \alpha^i \nabla L(\theta_{k-i}) \times \sum_{j=1}^{k} \alpha^j$: normalisation de la moyenne

- $\hat{m}_k$ permet la prise en compte de l'aspect global de la fonction
- $\hat{v}_k$ permet de ne pas tomber dans des minimums locaux

Comparaison des optimiseurs

SGD + momentum vs ADAM sur CIFAR-10

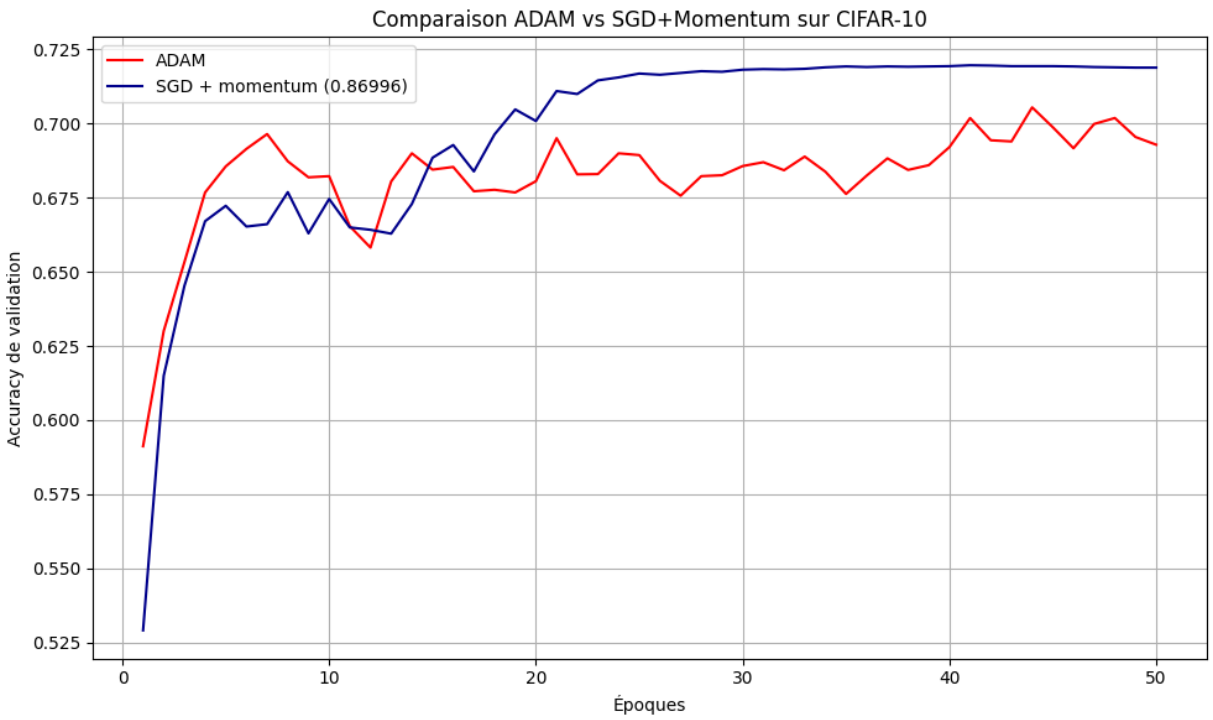

Les observations

$\longrightarrow$ Une meilleur accuracy en temps long avec SGD + Momentum

$\longrightarrow$ Une convergence initiale plus rapide avec ADAM

Comparaison des optimiseurs

Et en temps long

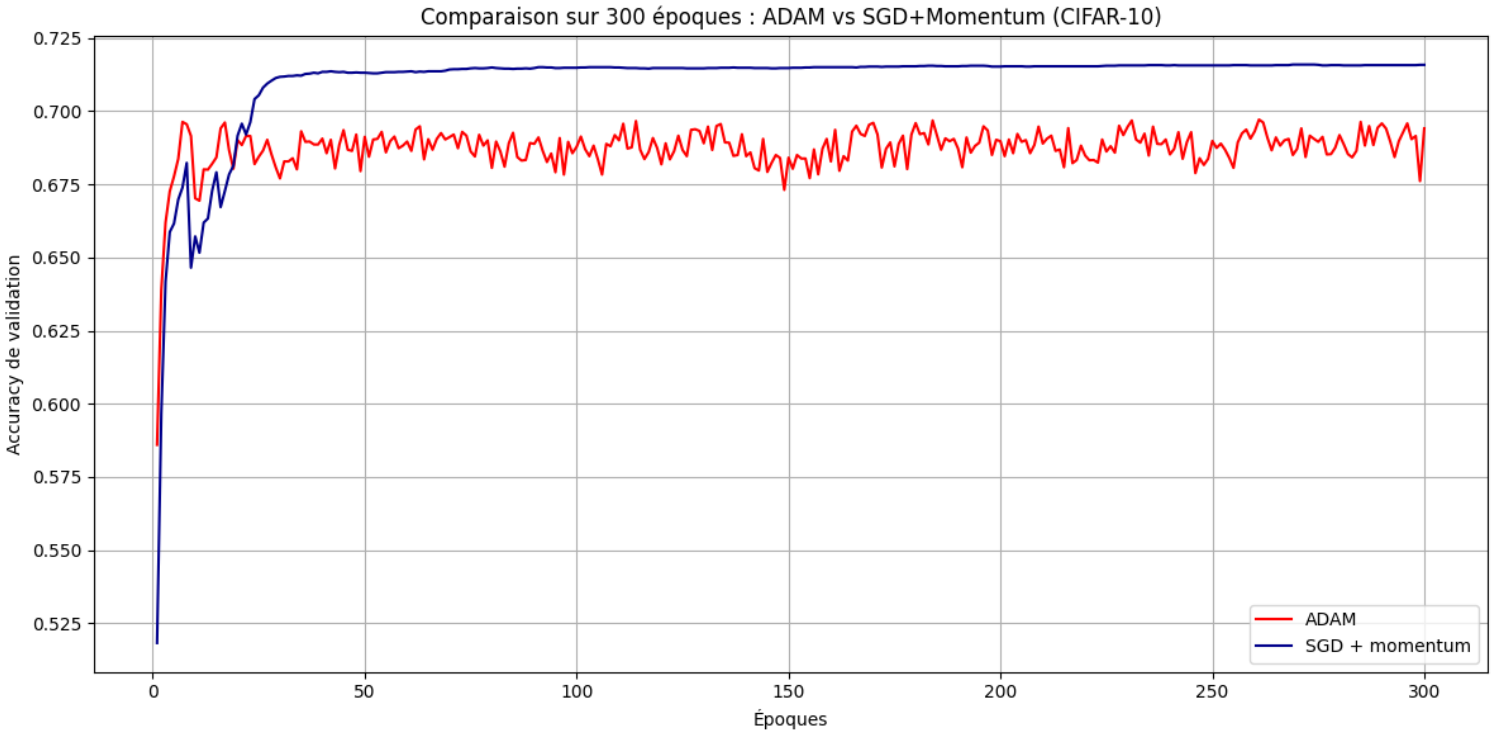

Les observations

$\longrightarrow$ SGD + Momentum est beaucoup plus stable (du fait de son pas constant).

Comparaison des optimiseurs

Une comparaison visuelle

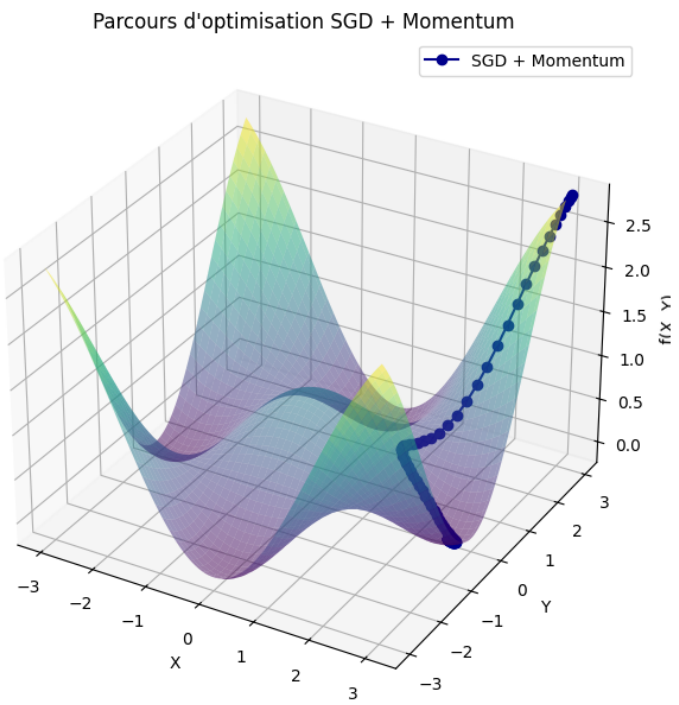

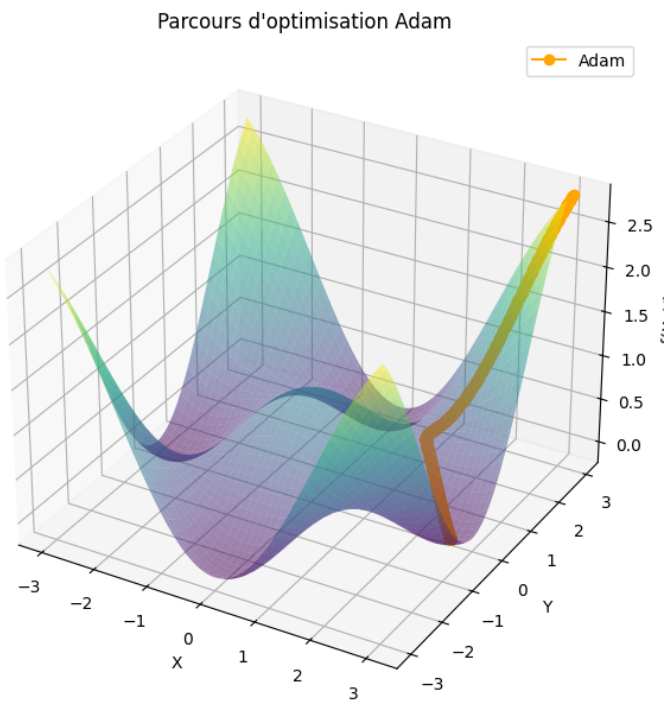

Les résultats

578 itérations avec ADAM contre 93 avec SGD + Momentum.

SGD semble plus performant pour ce type de problème.

Comparaison des optimiseurs

Peut-on généraliser les résulats vus avec CIFAR-10 ?

Sur une base de données complexe

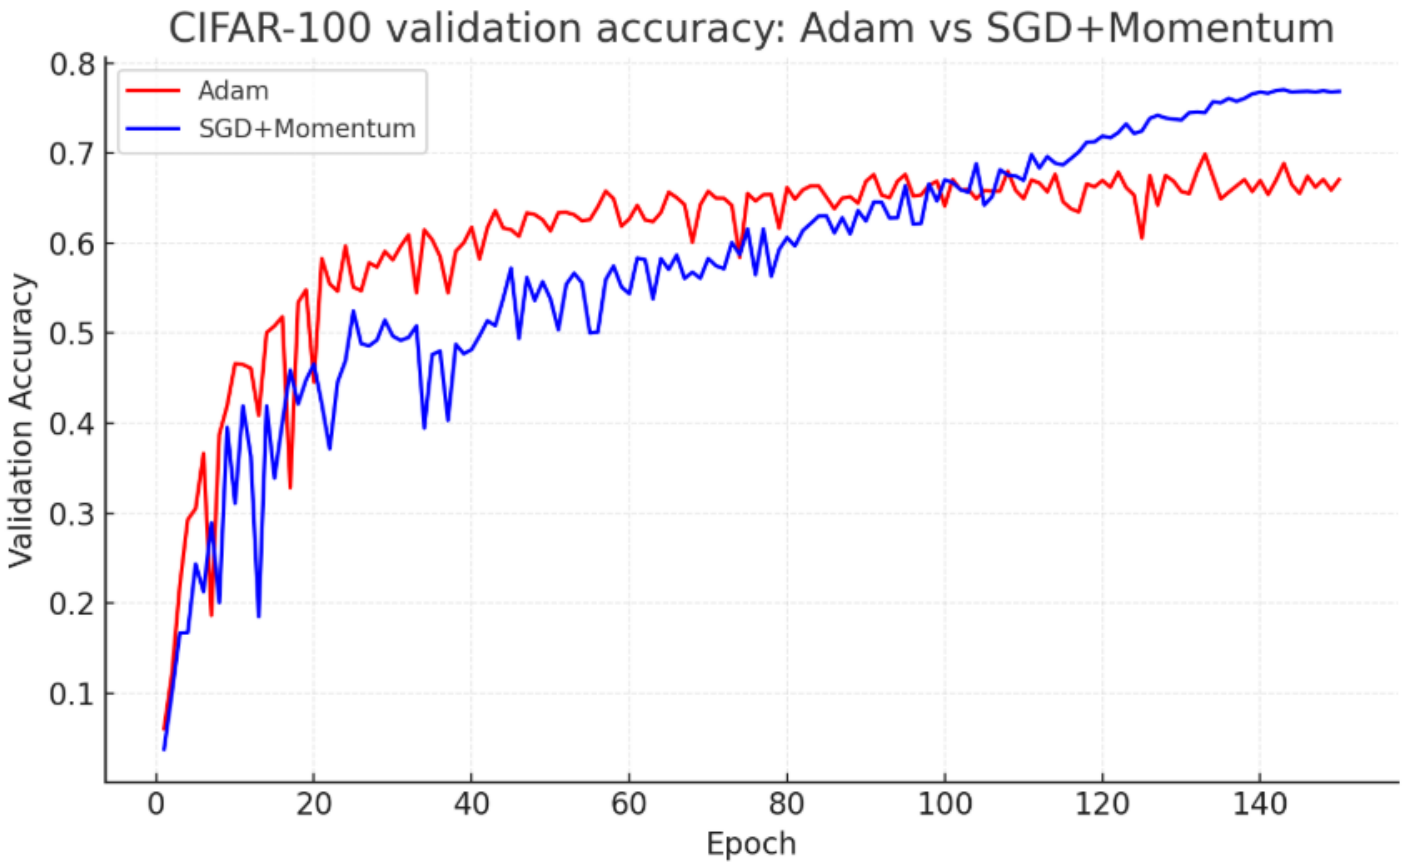

Comparaison des optimiseurs

Peut-on généraliser les résulats vus avec CIFAR-10 ?
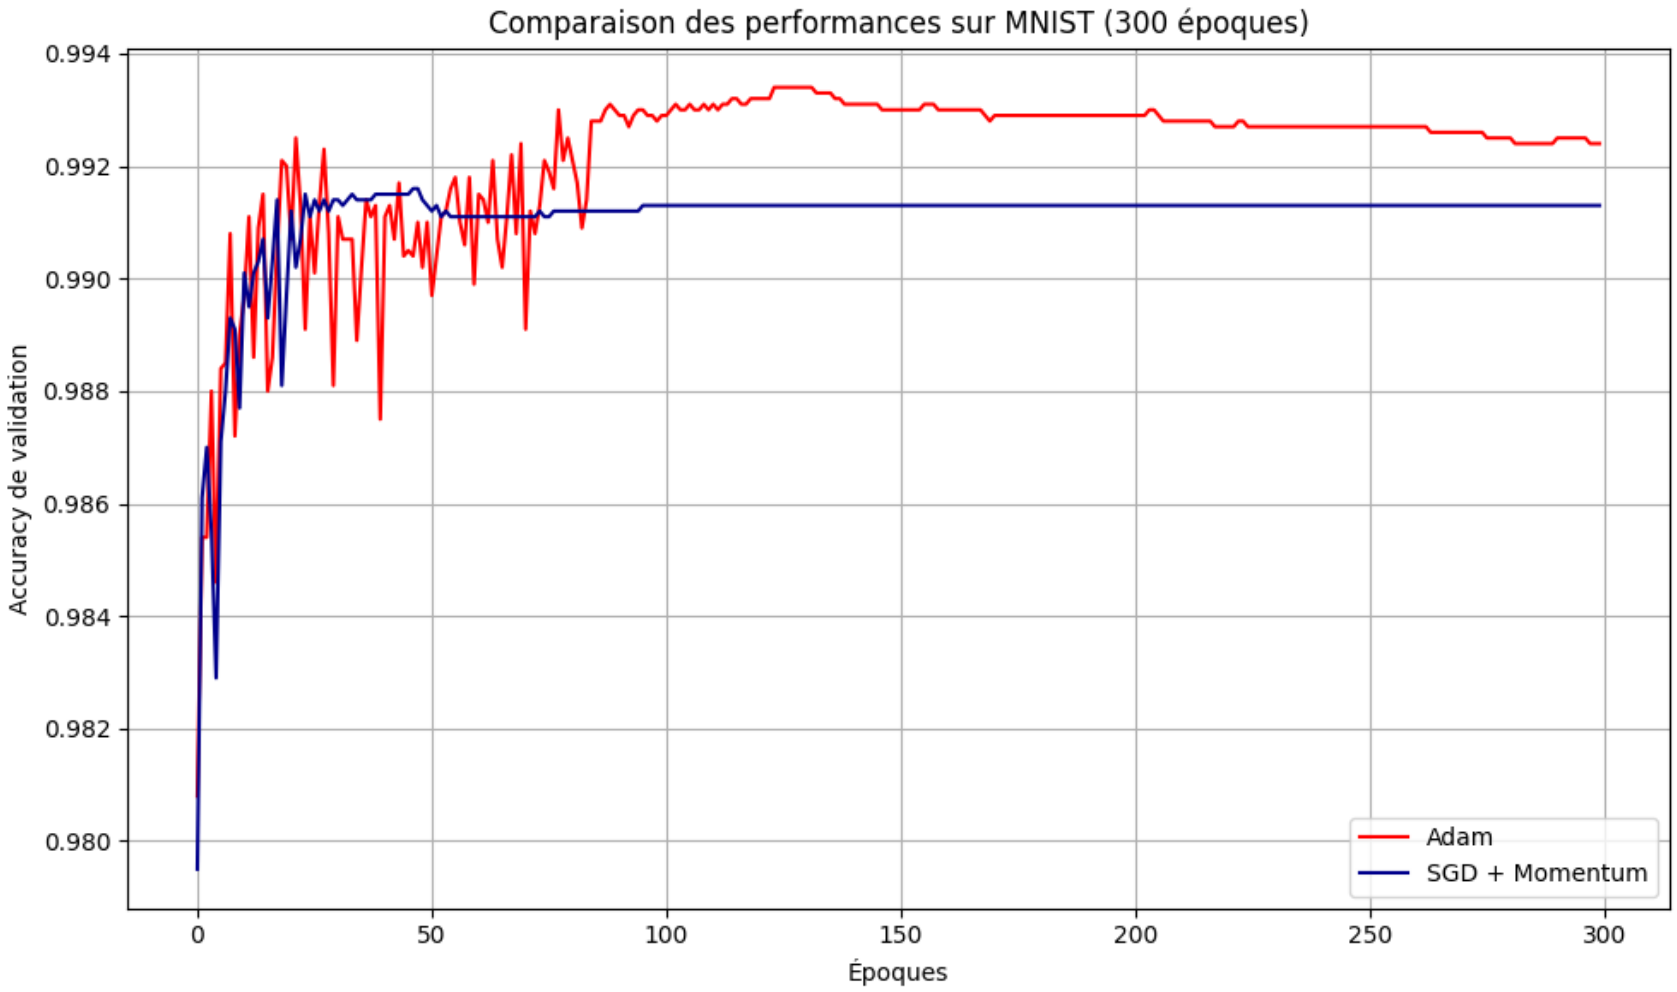
Sur une base de données très simple